

Analyse de la Qualite des Donnees de la Base RBE

Rapport d'audit qualite

07 May 2026

Contents

1	Presentation de la base	1
2	Analyse des Valeurs Manquantes	2
2.1	Taux de valeurs manquantes par variable	2
2.2	Repartition des valeurs manquantes par region	3
2.3	Repartition des valeurs manquantes par annee	4
2.4	Cartographie croisee des valeurs manquantes	5
2.4.1	Evolution des taux de NA par variable et par annee	5
2.4.2	Distribution des NA par variable et par region	6
3	Analyse des Erreurs de Saisie	6
3.1	Vue d'ensemble des erreurs identifiees	6
3.2	Erreur 1 : Pays dans le champ Est Une PPE	7
3.2.1	Repartition de l'Erreur 1 par region	8
3.2.2	Repartition de l'Erreur 1 par annee	8
3.3	Erreur 2 : Nom de personne dans le champ Fonction PPE	8
3.4	Erreur 3 : Libelle generique dans le champ NomPPE	10
3.5	Erreur 4 : Controle exhaustif des modalites	11
3.5.1	Erreur 4a : Valeur non-binaire dans Est Une PPE	11
3.5.2	Erreur 4b : Code binaire dans le champ Fonction PPE	11
4	Analyses Croisees : Comprendre les Valeurs Manquantes	13
4.1	Co-occurrence des NA dans les variables financieres	13
4.2	Profil des NA selon la nationalite	14
4.3	Profil des NA selon le pays de residence	16

1 Presentation de la base

La base RBE (Registre des Beneficiaires Effectifs) couvre cinq annees consecutives, a savoir 2021, 2022, 2023, 2024, 2025, et rassemble 628 beneficiaires effectifs repartis sur 9 regions du territoire senegalais, a savoir Dakar, Diourbel, Fatick, Kédougou, Kaolack, Mbour, Tambacounda, Thiès, Ziguinchor. Chaque enregistrement correspond a un beneficiaire effectif declare et renseigne, entre autres, son nom et prenom, la denomination de l'entreprise, la region de l'entreprise, ses parts d'actions directes, ses droits de vote, sa nationalite, son pays de residence, l'annee d'acquisition, son eventuelle qualite de Personne Politiquement Exposee (PPE), la fonction de la PPE et son nom. La base comprend au total 12 variables, soit 7 536 cellules a renseigner.

L'examen de la base revele deux familles de problemes de qualite. D'une part, un volume tres important de valeurs manquantes qui frappe l'ensemble des enregistrements, et d'autre part, des erreurs de saisie ponctuelles qui signalent des confusions entre champs lors de la collecte. Ces deux dimensions, bien que de nature


différente, compromettent la fiabilité de la base et réduisent sa valeur analytique et réglementaire. En effet, 23.04 % de la base présente des valeurs manquantes et les erreurs de saisie ne concernent que les variables Est Une PPE, NomPPE et Fonction PPE.

2 Analyse des Valeurs Manquantes

2.1 Taux de valeurs manquantes par variable

Tableau 1: Tableau 1 - Valeurs manquantes par variable (variables concernées uniquement)

Variable	Nb NA	% NA
NomPPE	610	97.1 %
Est Une PPE	535	85.2 %
% Voix Direct	263	41.9 %
% Action Direct	170	27.1 %
Fonction PPE	81	12.9 %
PaysResidence	77	12.3 %



L'analyse de la complétude des données met en évidence une dichotomie claire entre les informations administratives classiques et les indicateurs spécifiques aux PPE. Pour les variables telles que l'année, la dénomination sociale, le greffe, le prénom et nom, la nationalité et la région, le remplissage est optimal avec 0 % de valeurs manquantes. Cette exhaustivité parfaite s'explique par le caractère public et peu sensible de ces informations, qui constituent le socle d'identification standard de la base de données. Ces données sont généralement issues de sources secondaires fiables, comme le registre du commerce, ce qui garantit leur présence systématique.

A l'inverse, on observe une dégradation majeure de la qualité de l'information dès que les variables touchent à des domaines plus confidentiels ou complexes à documenter. Les champs relatifs à l'identification formelle sont


les plus critiques : la variable NomPPE est presque totalement absente avec 97.1 % de valeurs manquantes, tandis que le statut Est Une PPE fait défaut dans 85.2 % des cas. L'absence quasi systematique de ces deux variables suggere que les agents de collecte se heurtent a des difficultes specifiques pour identifier et documenter le statut PPE des beneficiaires, que ce soit par manque d'information disponible, par crainte de represailles, ou simplement par absence de formation adequate sur les criteres de qualification PPE.

Cette tendance a la hausse des donnees manquantes se confirme egalement pour les variables de participation financiere et de contexte. Le pourcentage de voix directes affiche une lacune de 41.9 %, et celui des actions directes s'eleve a 27.1 %. Ces taux d'omission sur les variables financieres sont preoccupants car ils privent l'analyse des informations centrales sur la structure de detention du capital. La Fonction PPE (12.9 %) et le Pays de Residence (12.3 %) presentent quant a eux des taux d'omission plus moderes, bien que neanmoins notables. Ces deux variables necessitent une investigation approfondie sur le terrain pour comprendre les raisons de leur non-renseignement.

2.2 Repartition des valeurs manquantes par region

Table 2: Tableau 2 - Valeurs manquantes par region

Region	Nb obs.	Nb NA total	Taux NA (%)
Dakar	456	1166	42.6
K<U+00E9>dougou	95	388	68.1
Thi<U+00E8>s	53	96	30.2
Diourbel	7	28	66.7
Mbour	7	26	61.9
Kaolack	3	12	66.7
Ziguinchor	3	9	50.0
Fatick	2	6	50.0
Tambacounda	2	5	41.7




L'analyse par region revele des disparites geographiques majeures. La region de Dakar cristallise a elle seule l'essentiel des lacunes, avec un total de 1166 valeurs manquantes, ce qui s'explique en partie par le poids demographique de la region qui regroupe 456 beneficiaires. Toutefois, le taux relatif de 42.6 % confirme que

la densité n'est pas le seul facteur explicatif : des problèmes structurels de collecte persistent dans cette région malgré sa dotation en ressources administratives. Kedougou occupe la deuxième position avec un profil de criticité encore plus élevé en proportion, soulignant que les régions périphériques souffrent de contraintes logistiques et de capacités de saisie limitées.

L'examen par variable souligne cependant une opacité quasi totale dans plusieurs localités. Des régions comme Kaolack et Diourbel présentent un déficit d'information absolu, avec 100 % de valeurs manquantes sur les variables financières clés que sont le pourcentage d'actions et le pourcentage de voix, ainsi que sur le statut de PPE. Cela traduit vraisemblablement une absence de supervision locale et un manque de retours d'information permettant de corriger les lacunes. Par ailleurs, si le pays de résidence a été renseigné pour beaucoup de régions, certaines zones de concentration importantes ne le sont pas, notamment Mbour, Thies, Kedougou et Dakar. Enfin, bien que la région de Ziguinchor présente un remplissage correct pour les variables financières, elle n'échappe pas à la tendance générale d'omission sur les variables PPE.

2.3 Répartition des valeurs manquantes par année




L'évolution temporelle globale montre que les valeurs manquantes sont présentes sans exception de 2021 à 2025. L'année 2023 se distingue particulièrement comme le point critique de la base de données, affichant le volume le plus élevé de données omises avec 672 valeurs manquantes, soit 50 % du total annuel. Cette année correspond vraisemblablement à une période de montée en charge du dispositif de collecte, sans que les processus de vérification et de validation aient encore été pleinement opérationnels.

Bien que le nombre brut de manquants diminue en 2024, on observe une remontée du taux de vacuité en 2025, soulignant une difficulté persistante à stabiliser la collecte des informations au fil du temps. Cette instabilité inter-annuelle signale l'absence d'une procédure de validation systématique mise en œuvre de manière continue : les améliorations constatées une année ne perdurent pas et ne bénéficient pas des acquis des périodes précédentes. Il est également important de noter que la réduction du volume brut de manquants en 2024 peut s'expliquer par un nombre total d'observations plus faible cette année-là, ce qui confirme le calcul du taux relatif.

2.4 Cartographie croisee des valeurs manquantes


2.4.1 Evolution des taux de NA par variable et par annee



L'analyse detaillee par variable et par annee revele des inversions frappantes dans la qualite de saisie. Les variables d'identification des PPE, a savoir Est Une PPE et NomPPE, affichent des taux de manque critiques depassant souvent 93 % entre 2021 et 2023. Cependant, un changement de pratique semble s'operer en 2024 ou ces variables deviennent presque totalement renseignees. Ce gain est toutefois contrebalance par une degradation totale de la variable Est Une PPE qui culmine a 100 % de manque cette meme annee, suggerant une confusion persistante sur la nature de ce champ. Enfin, l'annee 2025 presente le profil le plus alarmant concernant les donnees de localisation et d'identite, avec un taux de vacuite de 100 % pour le PaysResidence et 97,4 % pour le NomPPE.

Concernant les indicateurs de detention financiere, le pourcentage de voix directes et le pourcentage d'actions directes fluctuent de maniere erratique : ils atteignent leur pic de carence en 2023 avant de connaitre une relative amelioration, sans jamais atteindre une completude satisfaisante. Cette repartition montre que la fiabilite de la base de donnees depend fortement de l'annee consideree, aucune periode ne parvenant a securiser l'ensemble des variables sensibles simultanement. Cela indique que les efforts d'amelioration sont conduits de maniere sectorielle et non globale, corrigeant certaines lacunes tout en en introduisant d'autres.

2.4.2 Distribution des NA par variable et par region



La lecture croisee region-variable met en evidence des profils de lacunes qui varient sensiblement d’une localite a l’autre. Les variables PPE, a savoir NomPPE, Est Une PPE et Fonction PPE, forment un bloc homogene de criticite maximale dans pratiquement toutes les regions, attestant d’un probleme de collecte generalise et non circonscrit a une zone geographique particuliere. Cependant, des nuances importantes apparaissent pour les variables financieres. Thies et Ziguinchor presentent des profils de completude relativement satisfaisants pour le pourcentage d’actions et le pourcentage de voix, alors que des regions comme Kaolack, Diourbel et Fatick atteignent 100 % de valeurs manquantes sur ces memes variables. Ces contrastes suggerent que la capacite de collecte des informations financieres est liee a des facteurs locaux, qu’il s’agisse de la disponibilite des documents comptables, de la formation des agents, ou de la cooperation des entites declarantes.


3 Analyse des Erreurs de Saisie

3.1 Vue d’ensemble des erreurs identifiees

Table 3: Tableau 3 - Synthese des erreurs de saisie identifiees

Type	Variable	Description	Nb obs.	% base
Erreur 1	Est Une PPE	Nom de pays saisi dans un champ binaire (0/1)	17	2.71 %
Erreur 2	Fonction PPE	Nom de personne saisi dans le champ d’intitule de fonction	2	0.32 %
Erreur 3	NomPPE	Libelle generique saisi a la place d’un nom individuel	2	0.32 %
Erreur 4a	Est Une PPE	Toute valeur autre que 0 ou 1 dans Est Une PPE (inclut Erreur 1)	17	2.71 %

Erreur 4b	Fonction PPE	Code binaire (0 ou 1) trouve dans Fonction PPE (devrait contenir un intitule)	545	86.78 %
-----------	--------------	---	-----	---------



L'examen de la base revele 547 observations affectees par au moins une erreur de saisie, soit 87.1 % des enregistrements. Deux categories d'erreurs se distinguent nettement par leur ampleur. D'une part, l'Erreur 4b, qui signale la presence de codes binaires (0 ou 1) dans le champ Fonction PPE, concerne 545 observations. Ce constat est particulierement revelateur : le champ Fonction PPE etant destine a recueillir l'intitule de la fonction occupee par la PPE, y trouver des codes 0 ou 1 indique que les agents de saisie ont confondu ce champ avec le champ indicateur Est Une PPE. D'autre part, les Erreurs 1 et 4a, liees a la presence de noms de pays dans le champ Est Une PPE, concernent 17 observations et confirment une confusion symetrique dans l'autre sens. Ces deux types d'erreurs apparaissent ainsi comme les deux faces d'un meme probleme de comprehension du formulaire de collecte.


3.2 Erreur 1 : Pays dans le champ Est Une PPE

La variable Est Une PPE est un indicateur binaire qui n'admet comme valeurs valides que les codes 0 (non) et 1 (oui). Or, 17 observations contiennent un nom de pays dans ce champ, ce qui traduit une confusion manifeste entre la colonne Est Une PPE et la colonne PaysResidence lors de la saisie. Cette erreur est particulierement grave car elle conduit a une mauvaise qualification du statut PPE du beneficiaire : l'individu n'est ni identifie comme PPE, ni exclu de cette categorie, rendant son enregistrement inutilisable pour les analyses de conformite reglementaire.


Table 4: Tableau 4 - Valeurs erronees dans le champ Est Une PPE

Valeur saisie	Nb obs.	% des erreurs	% de la base
S<U+00C9>N<U+00C9>GAL	6	35.3 %	0.96 %
SENEGAL	5	29.4 %	0.8 %
EGYPT	3	17.6 %	0.48 %
<U+00C9>GYPTE	3	17.6 %	0.48 %

3.2.1 Repartition de l'Erreur 1 par region



3.2.2 Repartition de l'Erreur 1 par annee




La distribution regionale de l'Erreur 1 permet d'identifier les zones geographiques les plus exposees a cette confusion de champs. La concentration des erreurs dans certaines regions specifiques suggere que le probleme est lie a des pratiques de saisie propres a ces zones, vraisemblablement en raison d'un manque de formation ou de supervision locale. Par ailleurs, la distribution temporelle revele si cette erreur est recurrente ou si elle s'est progressivement resorbe au fil des annees. Une absence d'evolution positive indiquerait que les retours correctifs n'ont pas ete transmis aux agents de saisie.

3.3 Erreur 2 : Nom de personne dans le champ Fonction PPE

Le champ Fonction PPE est destine a recueillir l'intitule de la fonction occupee par la Personne Politiquement Exposee, par exemple Ministre, Directeur General ou Depute. Or, 2 observations contiennent le nom d'un individu dans ce champ. Cette confusion indique que le champ destine a decrire la nature de la fonction a ete utilise pour noter l'identite de la personne, information qui devrait figurer dans la variable NomPPE.

Erreur 2 : repartition par region



Erreur 2 : repartition par annee




Table 5: Tableau 5 - Detail des observations avec Erreur 2

Region	Denomination Sociale	Prenom et Nom	Valeur erronee	NomPPE	Annee
Dakar	SOCIETE DES MINES DU SENEGAL (SOMISEN)	NGAGNE DEMBA TOURE	CHIEKH AHMADOU BAMBA NIANG	les Directeurs g<U+00E9>n<U+00E9>raux des minist<U+00E8>res	2025
Dakar	SOCIETE DES MINES DU SENEGAL (SOMISEN)	NGAGNE DEMBA TOURE	CHIEKH AHMADOU BAMBA NIANG	les Directeurs g<U+00E9>n<U+00E9>raux des minist<U+00E8>res	2025

L'Erreur 2 se distingue par son caractere localise : les 2 observations concernees se concentrent dans un nombre reduit de regions et d'annees, ce qui suggere une confusion specifique a un operateur ou a une session de collecte particuliere. Le detail des enregistrements permet d'identifier precisement les entites concernees et de corriger les saisies. L'existence simultanee de cette erreur et de l'Erreur 4b dans le champ Fonction PPE illustre bien la double confusion qui peut s'operer : certains agents ont saisi un code binaire la ou un intitule etait attendu, tandis que d'autres ont saisi un nom de personne. Ces deux comportements refletent une absence de consignes claires sur la nature de l'information a renseigner dans ce champ.

3.4 Erreur 3 : Libelle generique dans le champ NomPPE

La variable NomPPE est destinee a recueillir le nom propre d'un individu specifique. Or, 2 observations contiennent le libelle generique designant un groupe de personnes et non un individu. Cette erreur temoigne d'une incomprehension du champ de saisie, probablement liee a l'absence de formation ou de documentation claire sur les regles de remplissage.




Table 6: Tableau 6 - Detail des observations avec Erreur 3

Region	Denomination Sociale	Prenom et Nom	Valeur erronee	Annee
Dakar	SOCIETE DES MINES DU SENEGAL (SOMISEN)	NGAGNE DEMBA TOURE	les Directeurs g<U+00E9>n<U+00E9>raux des minist<U+00E8>res	2025
Dakar	SOCIETE DES MINES DU SENEGAL (SOMISEN)	NGAGNE DEMBA TOURE	les Directeurs g<U+00E9>n<U+00E9>raux des minist<U+00E8>res	2025

L'Erreur 3 met en lumiere une incomprehension du formulaire de collecte : l'agent de saisie a renseigne une categorie fonctionnelle collective la ou un nom individuel etait attendu. Cela traduit probablement un manque

de documentation sur la distinction entre les champs NomPPE et Fonction PPE, mais aussi sur le niveau de granularite attendu pour l'identification nominative.

3.5 Erreur 4 : Controle exhaustif des modalites


3.5.1 Erreur 4a : Valeur non-binaire dans Est Une PPE

Table 7: Tableau 7 - Bilan de l'Erreur 4a

Element	Detail
Modalites valides attendues	0 (non-PPE) et 1 (PPE)
Nombre de valeurs non-conformes	17
Taux dans la base	2.71 %
Relation avec Erreur 1	L'Erreur 4a englobe l'Erreur 1 (17 obs.) et tout autre cas non-binaire

Table 8: Tableau 7a - Valeurs non-binaires dans Est Une PPE

Valeur non-conforme	Nb obs.	% des cas
S<U+00C9>N<U+00C9>GAL	6	35.3 %
SENEGAL	5	29.4 %
EGYPT	3	17.6 %
<U+00C9>GYPTE	3	17.6 %



L'Erreur 4a confirme que l'integralite des anomalies detectees dans le champ Est Une PPE se resume aux cas deja couverts par l'Erreur 1, a savoir des noms de pays. Cela signifie qu'aucune autre forme de valeur non-binaire n'est presente dans ce champ, ce qui est rassurant : les erreurs sont circonscrites a une confusion specifique et identifiable, plutot qu'a des saisies aléatoires.



3.5.2 Erreur 4b : Code binaire dans le champ Fonction PPE

Le champ Fonction PPE devrait contenir l'intitule de la fonction exercee par la PPE, un champ textuel par nature. Or, 545 observations presentent un code 0 ou 1 dans ce champ, soit 86.78 % de la base. Cette erreur

est de loin la plus fréquente de toutes celles identifiées et révèle une confusion systématique entre le champ indicateur Est Une PPE (qui lui peut contenir 0 ou 1) et le champ descriptif Fonction PPE.

Table 9: Tableau 8 - Codes binaires trouvés dans le champ Fonction PPE

Valeur saisie (erronee)	Nb obs.	% des erreurs 4b	% de la base
0	536	98.3 %	85.35 %
1	9	1.7 %	1.43 %



La distribution régionale de l'Erreur 4b met en évidence la région qui concentre le plus grand nombre de saisies erronées. Cette concentration géographique confirme que l'erreur n'est pas le fait d'un agent isolé mais d'une pratique répandue dans certaines zones. Par ailleurs, l'analyse temporelle permet de déterminer si cette confusion s'est progressivement installée ou si elle était déjà présente dès les premières années de collecte. Une persistance sur l'ensemble de la période indiquerait que le problème de compréhension du champ n'a

jamais ete corrige, alors qu'une augmentation recente signalerait l'introduction d'une mauvaise pratique au fil du temps.


4 Analyses Croisees : Comprendre les Valeurs Manquantes


4.1 Co-occurrence des NA dans les variables financieres

Une question centrale pour comprendre les valeurs manquantes est de determiner si les donnees financieres, a savoir le pourcentage d'actions directes et le pourcentage de voix directes, sont absentes de maniere independante ou conjointement. Ces deux variables mesurent respectivement la part du capital et des droits de vote detenus directement par le beneficiaire et devraient en principe suivre des trajectoires paralleles de remplissage, car elles sont generalement issues des memes documents comptables et collectees simultanement.

Table 10: Tableau 9 - Co-occurrence des valeurs manquantes dans les variables financieres

Statut	Nb obs.	% base
NA Action et Voix	160	25.5 %
NA Action uniquement	10	1.6 %
NA Voix uniquement	103	16.4 %
Tous deux renseignes	355	56.5 %





L'analyse de la co-occurrence revele un fort degre de concomitance entre l'absence du pourcentage d'actions et l'absence du pourcentage de voix. Ce constat suggere un probleme commun de collecte plutot que des omissions independantes : un beneficiaire dont le pourcentage d'actions est renseigne devrait logiquement avoir aussi son pourcentage de voix documente, ces deux informations etant collectees simultanement a partir des memes documents. L'analyse par annee apporte un eclairage supplementaire important : si la proportion d'observations avec les deux variables simultanement renseignees evolue positivement ou negativement selon les periodes, cela permet d'identifier les annees au cours desquelles les processus de collecte des donnees financieres ont ete les plus defaillants. A l'inverse, les annees ou la proportion de renseignement complet est elevee constituent des references positives dont les pratiques gagneraient a etre generalisees.

4.2 Profil des NA selon la nationalite


L'analyse par nationalite vise a determiner si les lacunes sont distribuees uniformement entre beneficiaires senegalais et etrangers, ou si l'une de ces populations presente un profil de completude specifique. Cette question est importante car les obligations declaratives sont les memes pour tous les beneficiaires, independamment de leur nationalite. Des disparites significatives indiqueraient donc soit une difficulte particuliere a collecter certaines informations aupres de l'une des populations, soit une moindre vigilance des agents de collecte pour certains profils de beneficiaires.

Table 11: Tableau 10 - Taux de NA par variable selon la nationalite


Nationalite	Nb obs.	% NA Action	% NA Voix	% NA Pays	% NA Est PPE	% NA Fonc.	% NA NomPPE
Etranger	70	48.6	58.6	1.4	90.0	2.9	91.4
Senegalais	558	24.4	39.8	13.6	84.6	14.2	97.8


Taux de NA par variable selon la nationalite

Senegalais contre Etrangers




Taux de NA selon la nationalite et l'annee







L'examen du profil des valeurs manquantes selon la nationalite revele des disparites qui ne sont pas uniformes selon les variables. Pour les variables PPE, les taux de manque sont generalement eleves dans les deux groupes, ce qui confirme que ce probleme est d'abord structurel et non lie a la nationalite du beneficiaire. En revanche, pour les variables financieres, on peut observer des ecart entre beneficiaires senegalais et etrangers. Ces differences peuvent s'expliquer par le fait que les beneficiaires etrangers ont des structures de detention plus complexes, impliquant des societes etablies dans plusieurs pays, ce qui rend la determenation et la declaration du pourcentage d'actions et de voix plus difficile. L'analyse croisee avec la region permet de distinguer si les disparites observees au niveau national sont d'abord liees a la nationalite elle-meme ou a la distribution geographique des beneficiaires etrangers, qui peuvent se concentrer dans certaines regions specifiques.

4.3 Profil des NA selon le pays de residence





L'analyse croisee du pays de residence avec les valeurs manquantes revele un profil distinct entre residents au Senegal et residents a l'etranger. Cette distinction est particulierement interessante pour les variables financieres, car les residents etrangers peuvent avoir des structures de detention plus complexes ou des obligations de divulgation differentes dans leur pays de residence, rendant la saisie de ces informations plus difficile pour les agents de collecte. Par ailleurs, l'evolution temporelle par groupe de residence permet de verifier si les ameliorations observees dans la collecte beneficient uniformement aux deux populations, ou si elles profitent davantage aux residents au Senegal, dont les informations sont generalement plus accessibles aupres des sources administratives locales. L'analyse par region enrichit encore ce tableau en montrant si les disparites entre les deux groupes sont consistantes dans toutes les zones geographiques ou si elles se manifestent principalement dans certaines regions.